



Кафедра кибернетики (№ 22)

Направление подготовки 09.04.04 Программная инженерия

к научно-исследовательской работе студента на тему:

Москва 2024

ЗАДАНИЕ

№ п/п	Содержание работы	Форма отчетности	Срок исполнения	Отметка о выполнении Дата, подпись
1.	Аналитическая часть			
1.1.	Анализ достоинств и недостатков алгоритмов и программных средств сегментации и классификации крюков и знамён, разработанных для Корпуса рукописного наследия Древней Руси	Раздел ПЗ		
1.2.	Исследование правил позиционирования крюков и знамён над словами в текстах рукописей	Раздел ПЗ		
1.3.	Анализ подходов к формированию и представлению обучающих выборок для нейросетевых моделей	Раздел ПЗ		
1.4.	<i>Оформление расширенного содержания пояснительной записки (РСПЗ)</i>	Текст РСПЗ		
2.	Теоретическая часть			
2.1.	Модификация модели представления результатов сегментации страницы с крюками и знамёнами	Описание модели		
2.2.	Разработка алгоритма генерации редактируемой цифровой копии страницы с крюками и знамёнами	Псевдокод, описание		
3.	Инженерная часть			
3.1.	Проектирование и разработка программных средств генерации редактируемой цифровой копии страницы с крюками и знамёнами	Описание архитектуры, программных средств		
3.2.	Интеграция программных средств сегментации в портале Корпуса рукописного наследия Древней Руси	Описание программных средств		
4.	Технологическая часть			
4.1.	Подготовка обучающей выборки для нейросетевой модели распознавания крюков и знамён	Описание подхода и результатов		
	<i>Оформление пояснительной записки (ПЗ) иллюстративного материала для доклада.</i>	Текст ПЗ, презентация		

ЛИТЕРАТУРА

1.	Гонсалес Р., Вудс Р. Цифровая обработка изображений. Издание 3-е, исправленное и дополненное. Москва: Техносфера, 2012. – 1104 с. ISBN 978-5-94836-331-8
2.	Григорьев Е. Пособие по изучению церковного знаменного пения. Рижская Гребенщиковская старообрядческая община, Рига 2001, 318 стр.
3.	Визильтер Ю.В., Желтов С.Ю., Бондаренко А.В., Ососков М.В., Моржин А.В. Обработка и анализ изображений в задачах машинного зрения: Курс лекций и практических занятий. – М.: Физматкнига, 2010. – 672 с. ISBN 978-5-89155-201-2
4.	Запрягаев С. А., Сорокин А. И. Сегментация рукописных и машинописных текстов методом диаграмм Вороного Вестник воронежского государственного университета №1, 2010 г URL: http://www.vestnik.vsu.ru/pdf/analiz/2010/01/2010-01-27.pdf
5.	Дьячье око. URL: http://www.dyak-okno.mrezha.ru/archive/bukvar4.rar
6.	Катаев П. Духовное значение знамен: Знамя Крюк Русская вера. 2016 URL: https://ruvera.ru/articles/znamya_kryuk

Дата выдачи задания:

Руководитель

Демидов Д.В.

(ФИО)

« 24 » февраля 2024 г.

Студент

Попов З.А.

(ФИО)

Реферат

Пояснительная записка содержит 36 страницы, 16 рисунков. Количество использованных источников – 16.

Ключевые слова: сегментация, классификации, крюки и знамена, выборка, датасет, нейросети.

Целью работы является создание объемной и качественной выборки для нейросети, создание инструментов поддержки крюков и знамен в портале Корпуса.

В первом разделе приведен анализ методов сегментации и классификации крюков и знамен используемых в портале, подходов к формированию выборки для нейросетей, расположению крюков и знамен в древнеславянских текстах.

Во втором разделе приведена модель и алгоритмы для сегментации и классификации крюков.

В третьем разделе приведено описание архитектуры портала для реализации задачи сегментации и классификации.

В четвертом разделе представлена выборка и подход к ее формированию, для обучения нейросети классификации крюков.

Содержание

Введение	5
1 Анализ методов и технологий обработки рукописного наследия	6
1. Анализ достоинств и недостатков алгоритмов и программных средств сегментации и классификации крюков и знамён, разработанных для Корпуса рукописного наследия Древней Руси	6
1.1. Средства сегментации крюков и знамен портала	6
1.2. Средства классификации крюков и знамен портала	7
2. Исследование правил позиционирования крюков и знамён над словами в текстах рукописей	11
3. Анализ подходов к формированию и представлению обучающих выборок для нейросетевых моделей	14
4. Выводы	17
5. Постановка задачи учебно исследовательской работы	17
2 Модель и алгоритмы для решения задачи сегментации и классификации крюков	18
1. Модификация модели представления результатов сегментации страницы с крюками и знамёнами	18
2. Алгоритм генерации редактируемой цифровой копии страницы с крюками и знамёнами	19
3. Выводы	21
3 Проектирование и разработка программных средств решения задачи сегментации и классификации крюков	22
1. Проектирование и разработка программных средств генерации редактируемой цифровой копии страницы с крюками и знамёнами	22
1.1. Требования к реализации	22
1.2. Модификация модуля сегментации	23
2. Интеграция программных средств сегментации в портал Корпуса рукописного наследия Древней Руси	25

3.	Выводы	27
4	Этапы формирования обучающей выборки для задачи классификации крюков и знамён	28
1.	Подготовка обучающей выборки для нейросетевой модели распознавания крюков и знамён	28
2.	Выводы	32
	Заключение	33

Введение

Изучение исторических документов играет важную роль в понимании культурной, социальной и политической истории страны. В последние годы возрос интерес к разработке методов автоматического анализа исторических документов с использованием техник машинного обучения и компьютерного зрения. В НИЯУ МИФИ открылась лаборатория цифровой лингвистики в сотрудничестве со специалистами Института русского языка им. В.В. Виноградова РАН в целях разработки новых методов цифрового анализа древнерусских рукописей. Основная цель лаборатории — создание и поддержка корпуса старославянского языка. Корпус языка используется для изучения различных аспектов языка, таких как грамматика, лексика, синтаксис, стилистика, дискурс и т. д. Для лингвистов корпус является основным инструментом поиска примеров того или иного феномена в языке. В целом, наша работа направлена на создание новых инструментов и методов для автоматического анализа исторических старославянских текстов.

Задача сегментации и классификации крюков в старославянских текстах является уникальной и сложной, поскольку первоочередная важность у проектов, подобных корпусу, заключается в классификации текстов. В результате, зачастую отсутствуют готовые решения для таких специфических задач. Специфичность данной задачи также накладывает ключевое ограничение — отсутствие датасетов или обширных выборок для её решения. Таким образом, для успешного выполнения задачи классификации и сегментации крюков необходимо, в первую очередь, собрать обширную выборку крюков, провести её корректировку с участием лингвистов и создать первую версию нейронной модели для сегментации крюков.

Дополнительной сложностью является разность крюков в старославянских текстах по времени: крюки претерпели значительные изменения, и крюки середины XVII века значительно отличаются от крюков XII - XVI веков. Более того, из-за изменения стандартов крюков многие рукописи переписывались поверх прежних текстов, что делает задачу ещё сложнее.

Наша работа посвящена созданию базовых средств для классификации крюков середины XVII века и последующему запуску нейронной модели для дальнейшей сегментации.

1. Анализ методов и технологий обработки рукописного наследия

1. Анализ достоинств и недостатков алгоритмов и программных средств сегментации и классификации крюков и знамён, разработанных для Корпуса рукописного наследия Древней Руси

1.1. Средства сегментации крюков и знамен портала

Для сегментации областей, которые потом будут классифицироваться, применяется алгоритм MSER.

Алгоритм MSER (Maximally Stable Extremal Regions) был предложен Матушем Матейкой и Джереми М. Максаном в 2002 году. Этот метод был разработан для выделения стабильных областей на изображении, которые остаются неизменными в широком диапазоне пороговых значений. MSER нашел широкое применение в задачах компьютерного зрения, таких как распознавание объектов, отслеживание и сегментация изображений[1].

Алгоритм состоит из следующих этапов:

Пороговая сегментация — Изображение многократно сегментируется при различных порогах. Для каждого порога определяются связные компоненты. Связанная компонента — это множество пикселей, которые соединены друг с другом и имеют одинаковое значение интенсивности.

Формула для пороговой сегментации:

$$I_T(x, y) = \begin{cases} 1 & \text{если } I(x, y) \geq T \\ 0 & \text{если } I(x, y) < T \end{cases},$$

Экстремальные области — связные компоненты, которые либо полностью темнее (темная область на светлом фоне), либо полностью светлее (светлая область на темном фоне), чем ее окружение.

Связанная компонента C при пороге T считается экстремальной областью, если:

$$\forall (x, y) \in C \quad \forall (x', y') \in \partial C \quad I(x, y) < I(x', y')$$

где ∂C — граница области C .

Стабильность области — определяется по изменению ее размера при изменении порога. Область считается максимально стабильной, если изменение ее размера минимально при изменении порога.

Формула для определения стабильности области:

$$\Delta(C) = \frac{|C_{T+\Delta T}| - |C_T|}{\Delta T}$$

где $|C_T|$ — размер компоненты C при пороге T . *Выбор максимальных стабильных областей*
Области, которые остаются стабильными в широком диапазоне порогов, выбираются в качестве конечных регионов.

Преимущества и недостатки MSER[2]

Преимущества

- Независимость от масштаба: MSER эффективно выделяет области при изменении масштаба изображения.
- Робастность к освещению: Метод хорошо работает в условиях изменяющегося освещения.
- Высокая производительность: MSER работает быстро и эффективно для многих приложений.

Недостатки

- Чувствительность к шуму: Алгоритм может выделять ложные области в присутствии значительного шума.
- Проблемы с текстурированными фонами: На текстурированных изображениях может выделяться много ненужных областей.

1.2. Средства классификации крюков и знамен портала

После сегментации изображения на устойчивые области, по каждой выделенной области собираются следующие признаки:

Моменты изображения — это количественные характеристики, которые описывают распределение пикселей в области. Они могут использоваться для вычисления различных свойств объекта, таких как площадь, центр тяжести и инерционные характеристики. Моменты до второго порядка часто используются для описания базовых свойств изображения[1].

Формула для вычисления геометрических моментов m_{pq} :

$$m_{pq} = \sum_x \sum_y x^p y^q I(x, y)$$

где $I(x, y)$ — интенсивность пикселя в точке (x, y) . Используются для:

- Оценки площади объекта.
- Нахождения центра масс объекта.
- Вычисления инерционных характеристик.

Ни моменты — это набор из 7 чисел, которые вычисляются с использованием центральных моментов и являются инвариантными к преобразованиям изображения. Первые 6 моментов инвариантны к переводу, масштабированию, вращению и отражению. При этом знак 7-го момента меняется при отражении изображения[3].

$$\begin{aligned}
 \phi_1 &= \eta_{20} + \eta_{02} \\
 \phi_2 &= (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \\
 \phi_3 &= (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \\
 \phi_4 &= (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2 \\
 \phi_5 &= (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2 \\
 \phi_6 &= (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03}) \\
 \phi_7 &= (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] - (\eta_{30} - 3\eta_{12})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2]
 \end{aligned}$$

Профили изображения[4]

- Вертикальный профиль: сумма пикселей в каждом ряду изображения. Он помогает понять вертикальное распределение интенсивности пикселей в изображении.

$$V(y) = \sum_x I(x, y)$$

где $V(y)$ — значение вертикального профиля на y -й строке, $I(x, y)$ — интенсивность пикселя в точке (x, y) .

- Горизонтальный профиль: сумма пикселей в каждом столбце изображения. Он помогает понять горизонтальное распределение интенсивности пикселей в изображении.

$$H(x) = \sum_y I(x, y)$$

где $H(x)$ — значение горизонтального профиля на x -й колонке, $I(x, y)$ — интенсивность пикселя в точке (x, y) .

Фурье-дескрипторы — это коэффициенты преобразования Фурье, которые используются для описания формы контура объекта. Они позволяют сравнивать формы объектов,

независимо от их положения, масштаба и ориентации[5].

Процесс вычисления Фурье-дескрипторов включает следующие шаги:

- Представление контура объекта в виде комплексной функции.
- Применение быстрого преобразования Фурье.
- Нормализация дескрипторов для обеспечения инвариантности к масштабу, вращению и сдвигу.

Формула для вычисления дескрипторов Фурье:

$$S(k) = \sum_{n=0}^{N-1} s(n)e^{-i\frac{2\pi kn}{N}}$$

где $S(k)$ — k -й дескриптор Фурье, $s(n)$ — координата n -й точки контура, N — общее количество точек на контуре.

Площадь символа Вычисляется через момент:

$$\text{area} = m_{00}$$

Центр тяжести — точка, представляющая собой среднее положение всех пикселей в объекте. Он характеризует положение объекта в пространстве изображения и используется для описания и анализа форм объектов, их отслеживания и выравнивания[6].

$$x_c = \frac{m_{10}}{m_{00}}, \quad y_c = \frac{m_{01}}{m_{00}}$$

Ориентация — угол, под которым ориентирован объект относительно осей координат. Вычисляется из ковариационной матрицы:

$$\text{angle} = \frac{1}{2} \arctan \left(\frac{2 \cdot \text{cov}(x, y)}{\text{var}(x) - \text{var}(y)} \right)$$

где $\text{cov}(x, y)$ — ковариация координат x и y , $\text{var}(x)$ и $\text{var}(y)$ — дисперсии координат x и y .

Эксцентриситет — мера отклонения формы объекта от круга. Вычисляется из ковариационной матрицы:

$$\text{eccentricity} = \sqrt{1 - \frac{\lambda_2}{\lambda_1}}$$

где λ_1 и λ_2 — собственные значения ковариационной матрицы.

Рациональность формы — это отношение площади к квадрату периметра объекта[7].

$$Rc = \frac{4\pi \cdot \text{area}}{\text{perimeter}^2}$$

где area — площадь объекта, perimeter — периметр объекта.

Отношение максимального диаметра к периметру

$$D/P = \frac{\max \text{ diameter}}{\text{perimeter}}$$

После обработки всех сегментов, для каждого сегмента мы получаем вектор признаков. Далее, перед тем как использовать эти признаки для классификации, мы применяем метод робастного масштабирования для нормализации данных.

Метод масштабирует признаки так, чтобы медиана каждого признака была равна нулю, а интерквартильный размах (разница между 75-м и 25-м перцентилями) — равен единице[8].

Для каждого признака x рассчитываем медиану Q_2 и интерквартильный размах $IQR = Q_3 - Q_1$, где Q_1 — это 25-й перцентиль, а Q_3 — это 75-й перцентиль. Преобразованный признак x' вычисляется как:

$$x' = \frac{x - Q_2}{IQR}$$

После масштабирования признаков сегментов, мы применяем логистическую регрессию для определения класса сегмента.

Логистическая регрессия — это метод машинного обучения, который используется для решения задач бинарной классификации. Целью логистической регрессии является предсказание вероятности принадлежности объекта к одному из двух классов на основе одного или нескольких (признаков). Основным компонентом логистической регрессии является логистическая функция (сигмоида), которая преобразует линейную комбинацию признаков в вероятность[9]:

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

где $P(y = 1|X)$ — вероятность принадлежности к классу 1, $\beta_0, \beta_1, \dots, \beta_n$ — параметры модели (веса), и $X_1, \dots, X_n$ — входные признаки.

Для определения весов логистической регрессии, мы подготовили обучающую выборку, состоящую из 100 аннотированных лингвистами страниц рукописей. Каждая страница была вручную сегментирована и классифицирована, что позволяет нам знать точный класс каждого сегмента. Модель логистической регрессии обучена таким образом, чтобы при сочетании весов с признаками сегмента вероятность правильной классификации была максимальной.

Для наших сегментированных областей, мы поступаем следующим образом: Для каждого класса модель логистической регрессии вычисляет вероятность принадлежности сегмента к этому классу. Затем для классификации сегмента мы выбираем класс с наибольшей вероятностью.

Подведем итоги сегментации представленной в Корпусе

Достоинства

- Устойчивость к выбросам: Использование масштабирования признаков делает модель менее чувствительной к выбросам, что повышает общую надежность и устойчивость классификации[10].
- Относительно высокая точность, если классифицируемая рукопись похожа на обучающую выборку

Недостатки

- Чувствительность к мультиколлинеарности: Модель логистической регрессии может быть чувствительна к сильной корреляции между признаками, что может ухудшить её способность к обобщению на новых данных[11].
- Ограниченная адаптация: Модель, обученная на одном наборе данных, может плохо адаптироваться к другим наборам данных, которые могут отличаться по качеству или характеру сегментов, требуя дополнительного обучения или доработки.
- Проблемы с редкими классами: Логистическая регрессия может плохо работать с очень редкими классами, так как данные для этих классов могут быть недостаточно репрезентативными, что приводит к плохой классификации таких сегментов.
- Проблемы с масштабируемостью: Хотя логистическая регрессия быстро обучается на небольших наборах данных, на очень больших и сложных наборах данных процесс обучения и предсказания может стать ресурсоемким и менее эффективным.




Рисунок 1.1 – Пример классификации крюков, при отсутствии их в обучающей модели. Снизу — сегментированные участки, сверху — их классификация.

2. Исследование правил позиционирования крюков и знамён над словами в текстах рукописей

Крюки и знамена — знаки русского старинного безлинейного нотного письма. Применялись в Русской Православной Церкви в XI–XVIII вв. Название получили от одного

из наиболее употребительных знаков этой системы — «крюка». Число крюков превышало 70, каждый из них обозначал от одного до нескольких звуков различной высоты и длительности. Пение по крюкам называлось крюковым, или знаменным пением[12].

Согласно [13], разнообразие знамен графически образуется из небольшого числа основных элементарных знамен.

✓ - Крюкъ	⚡ - Змѣница
└ - Стопѣца	⊖ - Дѣла
↙ - Статѣа	✕ - Кръжъ
└ - Пѣлка	↗ - Стрѣла
⬢ - Сложитѣа	↗ - Стрѣла трѣмѣна
⌒ - Запятѣа	↘ - Подчѣшѣе
✓ - Чѣшка	↗ - Параклѣтъ
⬢ - Скамѣнца	⬢ - Паѣкъ

Рисунок 1.2 – Начертания простых знамен.

Из начертаний отдельных знамен образуются целые сочетания, например.



Рисунок 1.3 – Пример сочетания знамен.

В основном у часто используемых крюков, встречаются 3 версии: простая, мрачная, и светлая



Рисунок 1.4 – Основная разновидность стрел.



Рисунок 1.5 – Основная разновидность статьи.

Опираясь на общие и усреднённые знания о крюках и знаменах, можно выделить несколько основных правил их позиционирования[13]:

- Стопица (см. рис. 1.6): Ставится на слогах, не имеющих ударения, или там, где напев движется звуками одинаковой высоты, рецитативом. Эти звуки не сильные, напоминают простой мерный шаг.
- Запятая (см. рис. 1.6): Понижает высоту в напеве или указывает низкий звук, от которого напев устремляется вверх. Звук большей силы, чем у стопицы. Преимущественно ставится над гласными.
- Крюк (см. рис. 1.6): Знамя крюка повышает высоту в напеве. Ставится на ударных слогах или слогах, наиболее важных по смыслу. В зависимости от значимости слога или высоты звука, крюк бывает простым, луночным и т. д. Обеспечивает полное, сильное и яркое звучание.
- Параклит (см. рис. 1.6): Ставится в начале слова или предложения, в котором содержится обращение к Богу, святым, часто в начале песнопения. Указывает на необходимость внимания и благоговения. На низких звуках обычно не используется. Звучит сходно с крюком простым.
- Статьи (см. рис. 1.6): Ставится чаще в конце попевок или на ударных слогах. В зависимости от значения звука или его высоты, как и крюки, бывает простым, луночным и светлым. Обеспечивает полное, сильное и яркое звучание, длительность несколько больше обычной.




Рисунок 1.6 – Основные крюки.

Во времена Древней Руси уровень грамотности был низким, и писари, занимавшиеся крюковой нотацией, часто опирались на свои локальные традиции и навыки. Хотя существовало общее понимание использования крюков, точных правил их позиционирования не было. Каждый писарь мог вносить свои индивидуальные особенности в запись крюков, что приводило к значительным региональным различиям. Это объясняет, поче-

му в разных рукописях встречаются уникальные крюки и варианты их расположения, не описанные в известных букварях[14].

Крюки использовались для распевки, поэтому их расположение над гласными буквами было естественным, так как именно гласные формируют пение. Однако из приведённых примеров ясно, что многие крюки могут обозначать общий характер пропева перед слогом, поэтому они могут располагаться над согласными буквами, перед слогами, в начале или в конце слова. Если идёт сложная и переливистая пропевка, крюки могут располагаться вне слов. Также не стоит забывать, что не все писари придерживались даже этих правил[14].




Рисунок 1.7 – Пример старославянской рукописи XVII века.

3. Анализ подходов к формированию и представлению обучающих выборок для нейросетевых моделей

Для формирования первичной выборки нейросетевой модели были выбраны различные рукописи XVII века. Эти рукописи обычно обладают более высоким качеством, что позволяет создавать высококачественную обучающую выборку. Высококачественные данные упрощают процесс обучения нейросетевой модели, повышая её точность и эффективность.

После сбора данных необходимо выполнить предобработку, чтобы повысить их общее качество и подготовить к обучению модели. Существуют различные подходы к предобработке данных:

Нормализация изображений: Приведение всех изображений крюков к единой форме и размеру (например, 64×64 пикселей). Это упростит обработку данных и их представление в модели. Однако возможна потеря деталей из-за масштабирования.

Улучшение качества изображений: Фильтрация шума и улучшение контрастности изображений с использованием различных алгоритмов фильтрации.

Кодирование категориальных данных: Кодирование категориальных признаков (например, типов крюков) в числовые значения с использованием методов, таких как one-hot encoding. Он подразумевает формирование бинарного вектора, где каждый столбец соответствует категории.

Аугментация данных: Для искусственного увеличения обучающей выборки используются методы аугментации данных.

- Геометрические преобразования: Применение преобразований, таких как вращение, сдвиг, масштабирование и отражение, к изображениям. Преобразования способствуют увеличению разнообразия данных и устойчивости модели к различным вариантам представления крюков.
- Цветовые преобразования: Изменение яркости, контраста и добавление цветового шума к изображениям. Модель станет устойчивей к некачественным данным.

Балансировка данных: Для устранения дисбаланса классов в данных используются следующие методы

- Oversampling: Увеличение числа данных меньшинств путём дублирования существующих примеров
- Undersampling: Уменьшение числа данных большинства путём удаления некоторых образцов.

Недостатком Oversampling является возможное переобучение на дублированных данных. Недостаток Undersampling в потере части данных. Для нашего проекта приоритетом является кол-во данных, так как результирующие нотированные нейросетью рукописи будут постоянно просматриваться и изучаться лингвистами.

- SMOTE (Synthetic Minority Over-sampling Technique): Генерация новых образцов меньшинств путём интерполяции между существующими данными.

Представление данных в виде тензоров: Каждое изображение крюка представляется в виде тензора размером $1 \times 64 \times 64$ (для черно-белых изображений). Тензорное представление позволяет эффективно обрабатывать изображения с использованием сверточных слоев. Тензорное представление данных позволяет удобно использовать сверточную нейросеть

Сверточная нейронная сеть: У данной разновидности нейронных сетей один из лучших алгоритмов распознавания и классификации изображений. По сравнению с полносвязной нейронной сетью у нее гораздо меньше количество настраиваемых весов. Главной особенностью свёрточной нейронной сети является «свертка». Процесс «свертки» представляет собой уменьшение размера матрицы признаков входного изображения [10]. Для получения ячейки матрицы уменьшенного размера элементы исходной матрицы в определенной области умножают на вес с последующим суммированием всех элементов в этой области. Чтобы получить следующую ячейку уменьшенной матрицы происходит

сдвиг области и выполнение тех же действий. Описанную выше последовательность действий можно записать формулой:

$$(I \times K)_{xy} = \sum_{i=1}^h \sum_{j=1}^w K_{ij} \times I_{x+i-1, y+j-1}$$

где I — исходная матрица признака, K матрица веса, x, y индексы выбранного блока, h, w — высота и ширина.




Рисунок 1.8 – Пример работы сверточной нейронной сети.

Подводя итоги методов и подходов формирования выборки, можно сделать вывод: Для нашей задачи наиболее подходящим методом является использование сверточных нейросетей, которые хорошо справляются с распознаванием и извлечением признаков из изображений. Основные аспекты нашей стратегии следующие:

- Выборка собирается вручную из хорошо бинаризованных рукописей XVII века. Это позволяет обеспечить высокое качество исходных данных, что упрощает процесс обучения модели.
- Нормализация изображений проводится с использованием масок размером 256×256 пикселей. Это обеспечивает единообразие и подходит для входных слоев нейросетей.
- Улучшение качества изображений (например, фильтрация шума или повышение контрастности) не требуется из-за высокой изначальной чёткости сканов.
- Категориальные данные кодируются сведениями о принадлежности крюка к определённому классу с использованием One-Hot Encoding или Label Encoding, что позволяет модели эффективно обучаться на этих данных.
- Основные геометрические преобразования включают масштабирование изображений до нужного размера. Повороты и отражения нецелесообразны в контексте крюков, так как они могут исказить их значение.
- Дополнительные методы аугментации включают наложение шумов и размытия.

Это повышает устойчивость модели и её способность к общему распознаванию символов в различных условиях.

- Для сбалансированной работы модели важно, чтобы обучающая выборка была разнообразной и включала равное количество примеров различных крюков.
- Выбор сверточной нейросети обуславливает необходимость наличия большой и сбалансированной выборки. В нашем случае, для балансировки данных целесообразно использовать метод OverSampling.

4. Выводы

1. Выполненный анализ средств классификации показывает их несостоятельность для крюков и знамен. Требуется улучшение модели классификации обновлением выборки или другой подход основанный на нейросетях.
2. Были исследованы правила позиционирования крюков в старославянских текстах. Часто встречаются локальные и региональные особенности, что не позволяет выработать единую четкую картину. Отсутствие единого стиля делает практически невозможной разработку обычного классификационного алгоритма связи букв и крюков.
3. Проанализированы подходы к формированию и представлению выборок данных для обучения нейросетевых моделей. Данный анализ позволяет выработать стратегию оптимального взаимодействия с собранными данными.

5. Постановка задачи учебно исследовательской работы

В рамках разработки системы сегментации и классификации крюков и знамен в старославянских текстах выделяются следующие задачи:

- Формирование выборки для нейросетевой модели распознавания крюков и знамен
- Модификация модели представления результатов сегментации страницы Корпуса, поддержка крюков и знамён
- Интеграция средств сегментации и классификации крюков в портал

2. Модель и алгоритмы для решения задачи сегментации и классификации крюков

1. Модификация модели представления результатов сегментации страницы с крюками и знамёнами

Модель представления результатов сегментации и классификации букв выполнена с использованием технологии HOCR, который является HTML-подобным форматом, разработанным для хранения информации о распознанных текстах, их координатах и структурных элементах. Этот формат позволяет легко интегрировать результаты сегментации в веб-приложения и обеспечивает гибкость в обработке текстов[15].

Однако на данный момент нейросетевая модель для распознавания крюков не готова к полноценному использованию. Результаты ее работы недостаточно точны, а производительность оставляет желать лучшего.

Основной задачей этой работы является участие в разработке портала, поэтому полноценное представление крюков в формате HOCR наравне с буквами – это задача не ближайшей перспективы.

Вместо этого, на данном этапе разработки необходимо сфокусироваться на модели, которая сможет ответить на вопрос: "Имеются ли крюки и знамена на данной странице рукописи?" Это позволит определить целесообразность запуска более сложной нейросетевой модели, процесс которой долгий и в текущем состоянии приводит к неточным результатам.

Для соответствия требованию определения наличия крюков на странице, модель должна содержать представление крюков для их линейного поиска. Результаты этого поиска должны включать информацию о количестве крюков и их расположении на странице.

Количество крюков является ключевым параметром, на основе которого будет приниматься решение о необходимости запуска нейросети. Расположение крюков служит вспомогательным атрибутом, необходимым для отслеживания и диагностики ошибок в случае неправильной сегментации или классификации. Точное указание местоположения крюков позволит эффективно выявлять и корректировать возможные недостатки в работе модели, обеспечивая более надежную и точную обработку данных.

Тогда модель классификации и сегментации крюков и знамен имеет вид:



Рисунок 2.1 – Модель классификации и сегментации крюков и знамен.

2. Алгоритм генерации редактируемой цифровой копии страницы с крюками и знамёнами

По описанным причинам из прошлого пункта, основная цель алгоритма — классификация крюков для определения необходимости запуска нейросетевой модели.

В качестве способа поиска крюков по маскам, выбран алгоритм сопоставления с шаблоном.




Рисунок 2.2 – Диаграмма алгоритма сопоставления с шаблоном.

Метод сопоставления с шаблоном представляет собой процесс поиска и идентификации участков изображения, которые соответствуют заранее определённым шаблонам. В случае нашего исследования, шаблонами являются бинарные маски крюков и знамен. Метод включает наложение шаблона на изображение и оценку степени совпадения, чтобы определить участки наиболее подходящих под шаблон.

В качестве метрики степени совпадения между шаблоном и изображением используется нормализованная сумма произведений:

$$R(x, y) = \frac{1}{N} \sum_{i=0}^{w-1} \sum_{j=0}^{h-1} T(i, j) \cdot I(x + i, y + j)$$

Где:

- $R(x, y)$ – степень совпадения на координатах (x, y) .
- $T(i, j)$ – значение пикселя шаблона в координатах (i, j) .
- $I(x + i, y + j)$ – значение пикселя изображения в координатах $(x + i, y + j)$.
- w и h – ширина и высота шаблона соответственно.
- N – общее количество пикселей в шаблоне ($N = w \cdot h$).

Параметр $R(x, y)$ будет оцениваться пороговым значением T , которое будет определять принадлежность сегмента изображения к крюку или знамени

Нормализованная сумма произведений была выбрана как метод оценки схожести шаблона и изображения, из-за своей быстроты, легкости в реализации, а также инвариантности к яркости[1].

3. Выводы

В результате разработки модели и алгоритмов была представлена модель, эффективно решающая задачу классификации крюков и знамен для определения необходимости использования нейросетевой модели. Использование подхода бинарных масок и шаблонного сопоставления позволяет достичь высокого быстродействия, что важно для оперативного принятия решений. Модель является легковесной и дообучаемой, что обеспечивает её адаптируемость при расширении выборки данных.

3. Проектирование и разработка программных средств решения задачи сегментации и классификации крюков

1. Проектирование и разработка программных средств генерации редактируемой цифровой копии страницы с крюками и знамёнами

1.1. Требования к реализации

Проектирование модели ведется в рамках работы над порталом, поэтому основные требования к ней исходят из задач и потребностей самого портала. Основной целью является создание системы, способной эффективно работать с текстами рукописного наследия, обеспечивая высокую скорость сегментации и классификации крюков и знамён.

Исходя из этого, основными требованиями к системе являются[16]:

- Сегментация и классификация крюков на изображении: Система должна анализировать входное изображение, выделять области, содержащие крюки, и определять их контуры и границы. Затем система должна классифицировать каждый выделенный крюк по классам, используя метод шаблонного сопоставления.
- Хранение данных: Система должна сохранять результаты сегментации и классификации в виде количества крюков на странице. Для каждого крюка должны сохраняться его координаты на изображении и его класс.
- Простая расширяемость: При дальнейшем дообучении модели на более ранних текстах (например, XVIII века) необходимо, чтобы система распознавания могла быть легко адаптирована для работы с новыми данными. Это обеспечит возможность расширения функционала модели без значительных модификаций её архитектуры, гарантируя её актуальность на протяжении долгого времени.
- Эффективность работы и скорость выполнения: Основной задачей модели является определение необходимости запуска нейросети. Время её работы должно быть сведено к минимуму, чтобы обеспечить высокую производительность портала. Это потребует оптимизации алгоритмов и внедрения эффективных методов обработки данных, чтобы пользователи могли получить результаты в кратчайшие сроки.

Архитектура системы распознавания портала представлена в виде:




Рисунок 3.1 – Архитектура системы распознавания.

1.2. Модификация модуля сегментации

Архитектурно, модуль сегментации имеет вид:




Рисунок 3.2 – Архитектура модуля сегментации.

Модулю ставится на вход задача сегментации изображения, на вход присылается обычное и бинаризованное изображение, после завершения обработки, модуль возвращает результат.

Для поиска крюков и знамен не требуется результат работы компонент модуля, поэтому не следует встраивать ее в общий пайплайн сегментации, что бы не путать разработчиков. Хорошим вариантом ее расположения будет или до начала пайплайна или по его завершению. На рис. 3.3 новая компонента модуля выделена пунктиром.

точной обработки, и реализации на C++.

Результаты поиска крюков с использованием бинарных масок следует хранить в виде количества найденных крюков и их точного расположения. Для представления расположения крюков был выбран формат JSON. Этот формат позволяет структурированно и наглядно описывать характеристики найденных объектов, такие как класс символа и координаты его местоположения.

```
[
  {
    "name": "image-0.11",
    "found_symbols": {
      "E009": [
        {
          "x": 912,
          "y": 1695,
          "width": 17,
          "height": 35
        }
      ],
      "E030": [
        {
          "x": 1589,
          "y": 1252,
          "width": 15,
          "height": 44
        }
      ]
    }
  }
]
```

Рисунок 3.4 – Пример Json файла для обработанного изображения.

Дополним задачу `tasks.segment`, являющуюся основной в модуле сегментации. Перед сегментации изображений запустим поиск крюков с помощью `cv2.matchTemplate`, на основе наших бинарных масок, указав точность соответствия в 85%.

Результат работы сегментации крюков запишем в результат работы модуля сегментатора.

Полученные в результате вызова API данные сегментации стоит записать в базу данных портала, для этого проведем миграцию базы данных Images, добавив колонку hooks,

отвечающую за кол-во найденных крюков.

БД портала основана на СУБД PostgreSQL, миграции осуществляются посредством alembic, что позволяет автоматизировать этот процесс.

3. Выводы

В результате проектирования модели и архитектуры для решения задачи сегментации и классификации крюков, полученная модель является легковесной, быстрой и легко расширяемой, посредством увеличения выборки.

4. Этапы формирования обучающей выборки для задачи классификации крюков и знамён

1. Подготовка обучающей выборки для нейросетевой модели распознавания крюков и знамён

Первоначальный этап включал создание шрифта, содержащего крюки и знамёна, с целью обеспечить совместимость результатов классификации с современными текстовыми редакторами. Кодирование классов осуществлялось с использованием Unicode-символов, соответствующих определённым символам в шрифте (например, Kruk.ttf). Это позволяет непосредственно использовать генерируемые классы в текстовых редакторах, таких как Microsoft Word, что значительно упрощает процесс внедрения результатов распознавания в практическое применение. (см. рис. 4.1 4.2).




Рисунок 4.1 – Отображение символов в шрифте Kruk.ttf.



Рисунок 4.2 – Классификация крюков в выборке.

Для формирования начальной выборки была выбрана рукопись XVII века, известная своим хорошим качеством и чёткостью изображений. Процесс предварительной обработки включал бинаризацию страниц рукописи с использованием метода Оtsu для улучшения контраста и выделения крюков. (см. рис. 4.3).




Рисунок 4.3 – Бинаризация страницы рукописи.

После бинаризации осуществлялось выделение каждого крюка на странице, исправление шумов, их классификация, а также вырезка и сохранение полученных изображений. Из-за специфичности задачи и отсутствия автоматизированных инструментов для классификации крюков, сборка начальной выборки выполнялась вручную с использованием графического редактора Paint.net. (см. рис. 4.4).



Рисунок 4.4 – Пример нарезанных символов.

Итоговая статистика "чистых" символов: (см. рис. 4.4).




Рисунок 4.5 – Статистика "чистых" символов.

В чистой статистике не учитываются крюки, которые встретились реже 10 раз, а также неопознанные, региональные особенности. Общее же количество нарезанных крюков: 1686.

Для увеличения объема выборки применялось масштабирование крюков, что дополнительно обогатило данные различными вариантами размеров символов. (см. рис. 4.6).



Рисунок 4.6 – Пример масштабируемого 9-го символа.

Для повышения устойчивости модели к различным возможным искажениям, в выборку добавлялись крюки с шумами и размытием. Это позволяет модели лучше справляться с вариативностью данных при реальном использовании. (см. рис. 4.7).



Рисунок 4.7 – Пример крюка с шумами.

Для достижения равномерности выборки был рассчитан средний объем выборки для 90% крюков. Недостаточно представленные классы были дополнительно уравновешены с использованием метода OverSampling.

Итоговая статистика по выборке: (см. рис. 4.8).

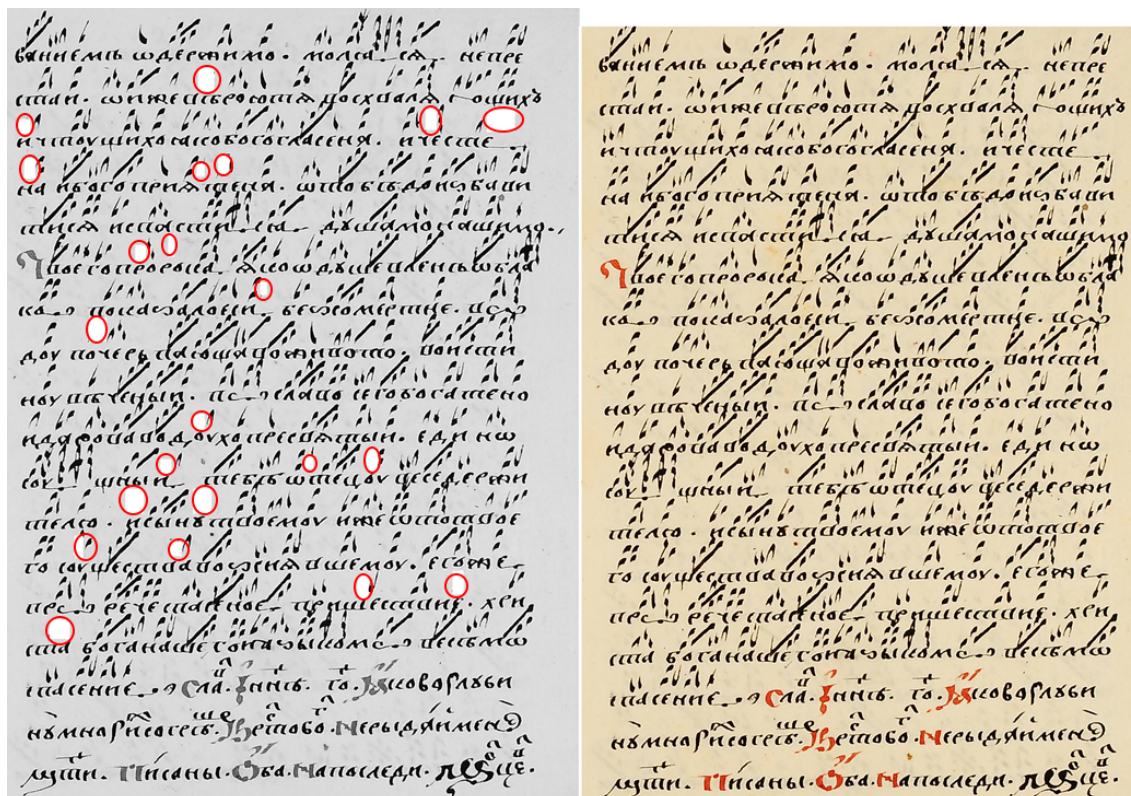


Рисунок 4.8 – Итоговая статистика по выборке.

2. Выводы

В ходе работы была сформирована обширная выборка, состоящая из 13 309 изображений крюков. Данная выборка сбалансирована и включает крюки различных размеров и качества изображений. На основе выборки будет обучаться нейросетевая модель для классификации и сегментации крюков и знамен.

Заключение

В ходе работы работы был проведен анализ средств классификации и сегментации крюков в портале, объяснена их несостоятельность по отношению к крюкам и знаменам, и сделан вывод о необходимости нового решения для портала, в частности, в виде нейросетевой модели.

Были изучены правила постановки крюков и знамен в текстах древней руси, результаты показывают крайнюю сложность в реализации любого логического алгоритма связи букв и крюков.

Анализ подходов к формированию выборки для нейросетевых моделей, сильно отразился на формировании итоговой выборки, сделав ее объемной и сбалансированной

Разработанная модель для сегментации и классификации крюков отвечает поставленной задаче, по решению о запуске нейросетевой модели.

Разработанная модель интегрирована в портал Корпуса рукописного наследия древней руси.

Сформирована обширная выборка крюков и знамен для обучения нейросетевой модели.

Список литературы

1. Гонсалес Р., Вудс Р. Цифровая обработка изображений. — Техносфера, 2005.
2. Принс С. Компьютерное зрение: современные алгоритмы и технологии. — ДМК Пресс, 2013.
3. Исаакян С. Л., Шафер И. Р., Шумайлов И. С. Основы цифровой обработки сигналов и изображений. — Санкт-Петербург : Питер, 2006.
4. Сойфер В. А. Методы компьютерной обработки изображений. — Физматлит, 2003.
5. Штепа Д. В. Анализ и распознавание изображений. — Москва : Физматлит, 2010.
6. Гладких А. В. Компьютерное зрение для анализа и распознавания символов. — Новосибирск : Наука, 2012.
7. Яровой В. С., Ивановский Г. О. Информационные технологии обработки и анализа форм. — Москва : Техносфера, 2011.
8. Хан Д. Интеллектуальный анализ данных: концепции и технологии. — МИР, 2012.
9. Сергеев И. Машинное обучение и аналитика данных. — Альпина Паблишер, 2019.
10. Иващенко А. Машинное обучение с использованием Python. — Питер, 2017.
11. Курдюмов С. Машинное обучение. Базовый курс. — БХВ-Петербург, 2018.
12. Казанцев М. Знаменное пение: История и традиции русской церковной музыки. — Издательский дом ЯСК, 2015.
13. Григорьев Е. Пособие по изучению церковного знаменного пения. — Рига : Рижская Гребенщицковская старообрядческая община, 1992.
14. Шульгин В. История русской музыки: Древнерусский период. — Наука, 2010.
15. Memon J., Sami R. A., D. K. U. Handwritten Optical Character Recognition (OCR): A Comprehensive Systematic Literature Review (SLR). — IEEE, 2022.
16. Леффингуэлл Д., Уидриг Д. Принципы работы с требованиями к программному обеспечению. — Издательский дом "Вильяме", 2000.